شبکه‌های عصبی و یادگیری عمیق
دکتر صفابخش

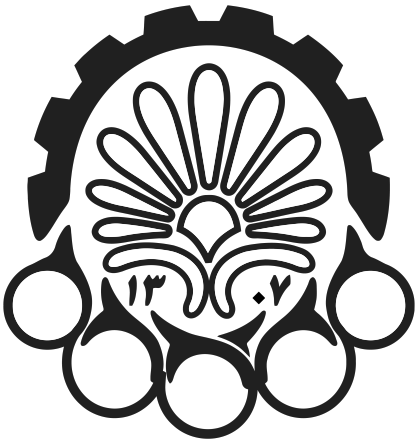

دانشگاه صنعتی امیرکبیر

(پلی تکنیک تهران)

دانشکده مهندسی کامپیوتر

رضا آدینه پور ۴۰۲۱۳۱۰۵۵

تمرین سوم

شبکه خودسازمان‌ده (SOM)

۷ اردیبهشت ۱۴۰۳

شبکه‌های عصبی و یادگیری عمیق

تمرین سوم

رضا آدینه پور ۴۰۲۱۳۱۰۵۵

دانشکده مهندسی کامپیوتر

سوال اول - عملی نظری

برای آموزش مدل‌های زبانی بزرگ (Large Language Model) که حاوی میلیون‌ها و میلیاردها پارامتر هستند، از حجم قابل توجهی داده استفاده می‌شود. اما در تمامی این مدل‌ها یک تاریخ قطع آموزش وجود دارد که مدل زبانی هیچ اطلاعاتی در خصوص داده‌های تولید شده‌ی پس از این زمان ندارد. به‌عنوان مثال، تاریخ قطع آموزش مدل GPT-3.5-turbu-instruction سپتامبر ۲۰۲۱ است و از همین رو این مدل ممکن است به سوالات مربوط به رویدادهای سال ۲۰۲۲، ۲۰۲۳ و ۲۰۲۴ پاسخ صحیح ندهد. چنین داده‌هایی که بعد از تاریخ قطع آموزش تولید شده‌اند و یا بخشی از داده‌ی آموزشی اولیه‌ی مدل زبانی نیستند را داده‌ی خارجی می‌گوییم. تکنیک تولید تقویت شده با بازیابی (RAG) رویکردی است که با استخراج داده‌ی خارجی متناسب با فرمان، دریافت شده و افزودن آن به‌عنوان ورودی به مدل زبانی تلاش می‌کند که فرمان ورودی را تقویت کرده و به مدل زبانی کمک می‌کند تا جواب مرتبط و متناسبی بسازد. به‌عنوان مثال در پاسخ به یک فرمان متنی مانند «چه‌کسی شرکت توییتر را درسال ۲۰۲۲ خرید؟» تمامی داده‌های خارجی متناسب با این فرمان را استخراج می‌کند و آن‌ها را به‌عنوان ورودی به مدل زبانی GPT-3.5-turbo-instruct می‌دهد تا مدل زبانی بتواند با دانش دریافت شده پاسخ متناسبی تولید کند. این رویکرد نیاز به آموزش مجدد و با بازتنظیم (Fine tune) مدل زبانی را برطرف می‌سازد. در این پروژه می‌خواهیم با استفاده از شبکه‌های خودسازمان‌ده این تکنیک را پیاده‌سازی کنیم.

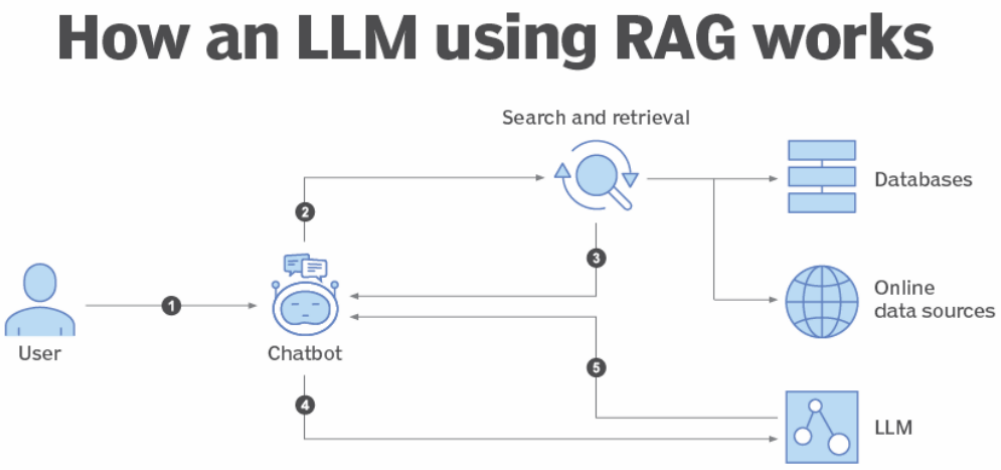

شکل ۱: فرآیند کلی RAG در یک مدل زبانی بزرگ

وظیفه اصلی RAG جست‌وجو معنایی (Semantic search) در پایگاه داده‌های اطلاعاتی و بازیابی اطلاعات خارجی دارای تناسب محتوایی با فرمان داده‌شده به یک مدل زبانی است.برای تسهیل جست‌وجوی معنایی، ابتدا داده‌های خارجی استخراج شده به بازنمایی‌های عددی یا برداری تبدیل می‌شوند که به این بازنمایی، تعبیه‌ی متن (Text embedding) می‌گوییم. در زمان بازیابی نیز ابتدا فرمان متنی به بازنمایی برداری تبدیل می‌شود و سپس نزدیک‌ترین بردارهای داده‌ی خارجی متناسب با آن استخراج می‌شود. شکل «۱» دیاگرام کلی این فرآیند را نشان می‌دهد. چالش اصلی این رویکرد این است که جست‌وجوی معنایی ذکر شده به دلیل نیازمندی به محاسبه‌ی فاصله‌ی بردار فرمان با حجم عظیمی از بردارهای داده‌ی خارجی، به منابع پردازشی و

محاسباتی زیاد و زمان قابل توجهی نیاز دارد. بنابر این پیدا کردن رویکردی که جست‌وجوی معنایی را به‌صورت کارا انجام دهد بسیار حائز اهمیت است.

برای افزایش کارایی جست‌وجو معنایی، یک رویکرد رایج این است که بردارهای داده‌های خارجی را خوشه‌بندی کنیم و در زمان جست‌وجو نیز ابتدا خوشه مشابه با بردار فرمان ورودی را پیدا می‌کنیم و سپس شباهت بردارهای داده‌های خارجی متعلق به آن خوشه با بردار فرمان را محاسبه می‌کنیم و اگر شباهت بردارها از یک آستانه بیشتر باشد، آنها را به‌عنوان اطلاعات مرتبط درنظر می‌گیریم.

۱. در این پروژه قصد داریم برای خوشه‌بندی داده‌های خارجی از شبکه خودسازمان‌ده استفاده کنیم. بررسی کنید که در این شبکه‌ها نسبت به سایر روش‌های خوشه‌بندی که در یادگیری ماشین به‌کار گرفته می‌شود، چه مزایا و معایبی دارد؟ به نظر شما، چرا استفاده از شبکه خودسازمان‌ده به صورت با نظارت صورت نمی‌گیرد؟ فرآیند یادگیری این مدل‌ها را توضیح دهید.

پاسخ

قبل از بررسی مزایا و معایب شبکه SOM نیاز است که یک‌سری پیش‌نیاز ها را توضیح دهیم. پیش از هر چیزی ابتدا می‌بایست انواع الگوریتم های یادگیری ماشین و دلیل استفاده از آنهارا توضیح دهیم. الگوریتم های یادگیری ماشین به ۳ دسته مختلف تقسیم می‌شوند:

(آ) یادگیری با نظارت (Supervised Learning)

(ب) یادگیری نیمه نظارتی (Semi-supervised Learning)

(ج) یادگیری بدون نظارت (Unsupervised Learning)

در یادگیری بانظارت، داده و لیبل‌های متناظر با آنها را داریم. در یادگیری نیمه نظارتی، صرفا بخشی از داده‌ها لیبل دارند و لیبل بقیه داده‌ها مشخص نیست. دسته آخر که مورد بحث ماست، یادگیری بدون نظارت است که داده‌های موجود، لیبل ندارند و به ازای داده‌های مختلف، خروجی مناسب را نمی‌دانیم و از الگوهای پنهان در داده‌ها اطلاعی نداریم. در این صورت است که به سمت الگوریتم‌های بدون نظارت می‌آییم تا به الگوریتم این اجازه را بدهیم که هرچه را می‌تواند یاد بگیرد و اطلاعات پنهان در داده‌ها را مشخص کند. الگوریتم‌های خوشه‌بندی در این دسته قرار می‌گیرند و دلیل قرارگیری در این دسته آن است که ما هیچ اطلاعاتی درمورد داده‌های ورودی نداریم و به دنبال ایجاد وابستگی میان آنها هستیم. الگوریتم‌های خوشه‌بندی این امکان را برای ما فراهم می‌سازد تا داده‌های شبیه به هم را در یک دسته قرار دهد. در این باره در صفحه ۱۴۱ [۱] گفته شده است:

« **تکنیک‌های خوشه‌بندی زمانی اعمال می‌شوند که کلاسی برای پیش‌بینی وجود نداشته باشد، بلکه زمانی که نمونه‌ها باید به گروه‌های طبیعی تقسیم شوند، اعمال می‌شوند.** »

پس اگر با داده‌هایی مواجه بودیم که اطلاعاتی در مورد آنها نمی‌دانیم، خوشه‌یابی بهترین روش برای درک وابستگی‌ها میان داده‌هاست. الگوریتم‌های خوشه‌یابی را می‌توان به‌صورت زیر دسته‌بندی کرد:

(a) Density-based

(b) Distribution-based

(c) Centroid-based

(d) Hierarchical-based

در الگوریتم‌های خوشه‌یابی مبتنی بر چگالی، داده‌ها بر اساس تراکم و غلظت داده‌ها در نقاط مختلف تقسیم‌بندی می‌شود.

پاسخ

در خوشه‌یابی توزیع شده، اساس خوشه یابی به‌صورت احتمالی است. یعنی برای تمام نقاط یک احتمال تعلق به یک خوشه خاص درنظر گرفته می‌شود که با دور شدن داده از مرکز آن خوشه، احتمال تعلق داده به خوشه مربوطه کاهش پیدا می‌کند.
پرکاربرد ترین و سریع‌ترین نوع خوشه‌یابی، خوشه‌یابی Centroid است. این الگوریتم نقطه‌ها را بر اساس چندین مرکز در داده‌ها جدا می‌کند و هر نقطه بر اساس مجذور فاصله‌اش تا مرکز داده به یک خوشه اختصاص می‌یابد.
استفاده از خوشه‌بندی سلسله‌مراتبی محدود تر از سایر روش هاست. بدین صورت است که برای داده‌هایی که ذاتا به صورت سلسله‌مراتبی هستند استفاده می‌شود. مانند داده‌های مربوط به یک پایگاه داده.
الگوریتم های مختلفی برای خوشه‌یابی وجود دارد که می‌توان چندتا از آنها را به‌صورت زیر نام برد:

(a) SOM

(b) K-means

(c) DBSCAN

(d) Gaussian Mixture

(e) BIRCH

(f) Affinity Propagation

(g) Mean-Shift

(h) OPTICS

در این سوال به بررسی دو مورد از مهم‌ترین الگوریتم ها یعنی SOM و K-means می‌پردازیم.

(آ) **K-Means:** الگوریتم K-Means یک الگوریتم بدون نظارت، مبتنی بر مرکز و تکراری (iterative) است که داده های ورودی را دریافت می‌کند و آنها را به K دسته تقسیم می‌کند. مقدار K می‌بایست از قبل مشخص باشد. هدف در الگوریتم K-Means به حداقل رساندن مجموع فواصل بین دو نقطه داده شده و خوشه مربوط به آنهاست و تا زمانی که مینیمم فاصله را پیدا نکند، الگوریتم متوقف نمی‌شود.

ذکر این نکته الزامی است که در این الگوریتم، آموزشی‌ای صورت نمی‌گیرد و صرفا یک کار تکراری چندین بار تکرار می‌شود تا زمانی که بهینه‌ترین حالت پیدا شود.

شکل «۲» نحوه عملکرد الگوریتم K-Means را نشان می‌دهد.

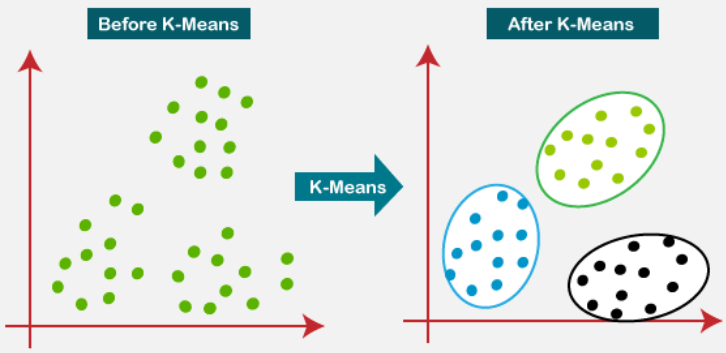

شکل ۲: ساختار الگوریتم K-Means

پاسخ

مراحل انجام الگوریتم K-Means به‌صورت زیر است:

(آ) **مرحله ۱:** انتخاب مقدار K بر اساس تعداد خوشه‌ها. اگر تعداد خوشه‌ها را نمی‌دانیم، عددی بزرگ را انتخاب می‌کنیم.

(ب) **مرحله ۲:** انتخاب K نقطه به‌صورت رندم و تصادفی.

(ج) **مرحله ۳:** قرار دادن هر نقطه در نزدیک‌ترین مرکز آن. (مرکز K خوشه‌ای که از قبل تعیین شده است.)

(د) **مرحله ۴:** واریناس را حساب کرده و مرکز جدید را برحسب واریانس انتخاب کرده

(ه) **مرحله ۵:** تکرار مرحله ۳. یعنی قرار دادن هر نقطه در مرکز جدید تعیین شده

(و) **مرحله ۶:** اگر هر تخصیص مجددی رخ داد به مرحله ۴ باید برویم درغیر این صورت به مرحله ۷

(ز) **مرحله ۷:** پایان الگوریتم

برای درک بهتر، در ادامه با رسم شکل مراحل بالا را توضیح خواهیم داد. فرض شود که داده‌های ورودی ما به‌صورت زیر باشد:

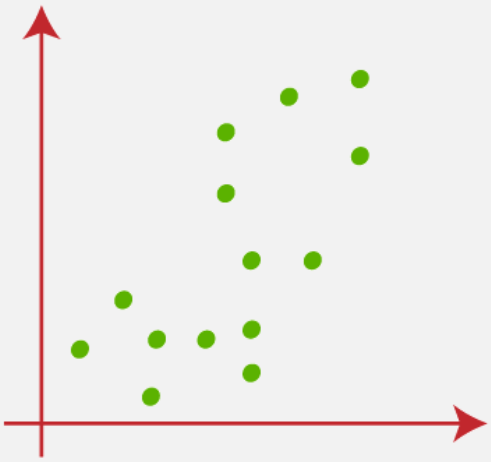

شکل ۳: داده‌های ورودی

در اینجا چون تعداد خوشه‌ها برای ما مشخص است، مقدار K را ۲ فرض می‌کنیم. و دو نقطه به‌صورت رندم در صفحه به‌عنوان نقاط شروع الگوریتم انتخاب می‌کنیم. شکل «۴»

پاسخ

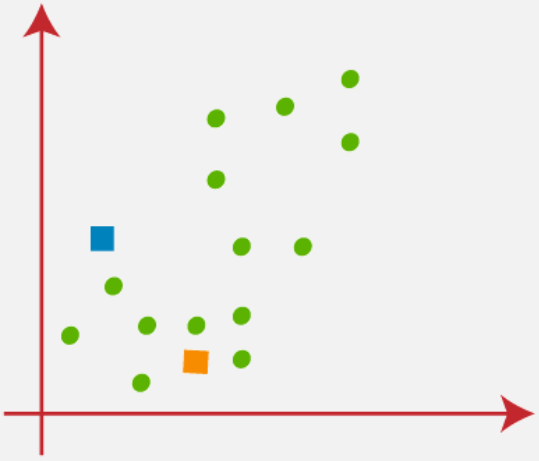

شکل ۴: نقاط ابتدایی الگوریتم

اکنون هر نقطه را به نزدیک‌ترین مرکز اختصاص می‌دهیم. این عملیات با محاسبه فاصله بین نقطه‌ها انجام می‌شود. سپس به مرحله آپدیت مرکز می‌رویم و برحسب واریانس محاسبه کرده، مرکز نقاط را آپدیت می‌کنیم. شکل «۵»

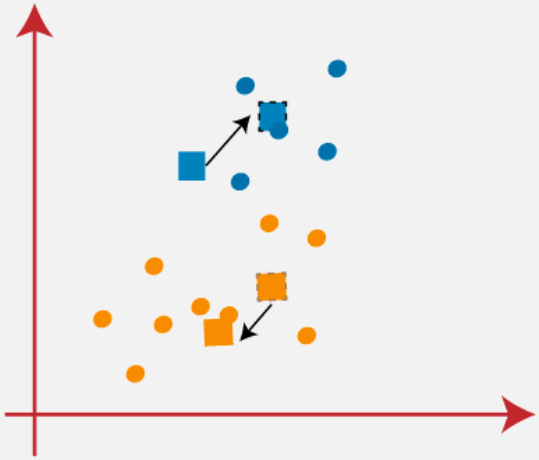

شکل ۵: آپدیت مراکز

این فرآیند را آنقدر ادامه می‌دهیم تا مینیمم ترین فاصله نقاط از مراکز به‌دست آید و داده‌ها خوشه‌بندی شود. شکل «۶»

پاسخ

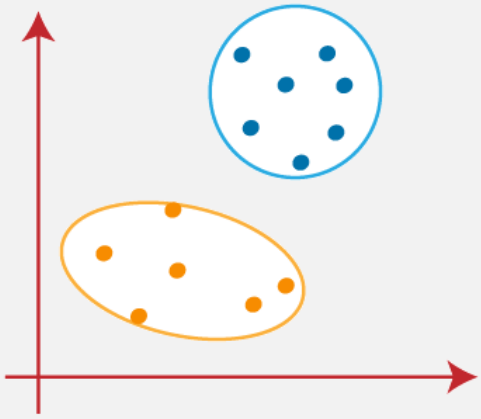

شکل ۶: داده‌های خوشه‌بندی شده

(آ) **SOM:** SOM بر خلاف K-Means یک شبکه عصبی است که بر اساس یادگیری بدون نظارت کار می‌کند. شبکه SOM کاربردهای مختلفی دارد. کاربرد اصلی شبکه SOM نگاشت داده‌های با بعد بالا به داده‌هایی با بعد پایین است. اما از این شبکه برای خوشه‌یابی نیز استفاده می‌شود شبکه SOM تنها از دو لایه تشکیل می‌شود. (لایه ورودی + خروجی) که لایه خروجی می‌تواند به صورت پشت سر هم و یا در یک ساختار شبکه ای قرار گیرند. شکل «۷»

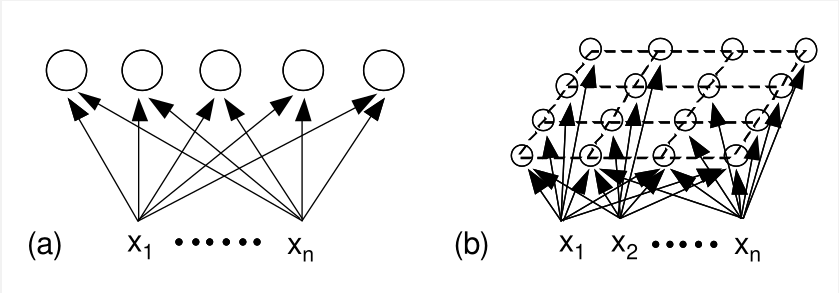

شکل ۷: ساختار شبکه SOM

در فرآیند آموزش وزن‌های متصل از ورودی به خروجی آموزش داده می‌شوند و در نهایت، هر نورون نماینده یک دسته (خوشه) از داده‌های ورودی است. الگوریتم یادگیری در SOM، رقابتی (Competitive) است. یعنی نورون‌های خروجی باهم بر سر نماینده شدن برای داده‌های ورودی رقابت می‌کنند و نورون برنده وزنش به نسبت نورون بازنده بیشتر اصلاح می‌شود. در SOM نیز همانند K-Means اگر تعداد خوشه‌ها را از قبل نمی‌دانستیم می‌بایست عدد بزرگی را برای آن درنظر بگیریم. [۲]

الگوریتم رقابتی در SOM را می‌توان به دو صورت انجام داد.

i. ارسال سیگنال به نورون‌های دیگر
ii. محاسبه فاصله تا ورودی

معمولا در تمامی شبکه‌های SOM متداول است که از روش دوم استفاده شود اما در ادامه توضیح هر دو روش را خواهیم داد.

پاسخ

برای روش اول داریم:
ابتدا می‌بایست هر نرون خروجی‌اش را به صورت زیر تولید کند:

$$u_j = \sum_{i-1}^{n} w_{ij} x_i$$

پس از محاسبه u_j هر نورون خروجی u_j خودش را با علامت معکوس به تمامی نورون‌های دیگر می‌فرستد. نورون‌ها پس از دریافت سایر u_j ها، می‌بایست مقادیر u_j های خودشان را با سایر u_j های وارد شده جمع کنند. حالا اگر مقدار حاصل از یک آستانه کمتر شود، (مثلا صفر) نورون مربوطه از رقابت خارج می‌شود. این فرآیند تا زمانی ادامه پیدا خواهد کرد که فقط یک نورون باقی بماند و آن نورون به عنوان نورون برنده مشخص می‌شود.
همانطور که گفته شد معمولا از این روش استفاده نمی‌شود و از روش دوم استفاده می‌شود. یعنی محاسبه فاصله تا ورودی. در این روش فاصله بردار ورودی طبق یکی از روابط تعیین فاصله (در اینجا فاصله اقلیدسی) برای تمامی وزن‌ها محاسبه می‌شود و نورونی که کمترین فاصله با بردار ورودی را داشته باشد به‌عنوان نورون برنده مشخص می‌شود.

$$d_j = x - w_j = \sqrt{\sum_{i=1}^{n} (x_i - w_{ij})^2}$$

پس از محاسبه همه فاصله‌ها، مقدار وزن نورون برنده به‌صورت زیر آپدیت می‌شود:

$$\Delta w_j = \beta(x - w_j) = \beta d_j$$

در نهایت، پس از همگراشدن شبکه، داده‌ها همگی در خوشه‌های مربوط به خودشان قرار می‌گیرند. شکل«»

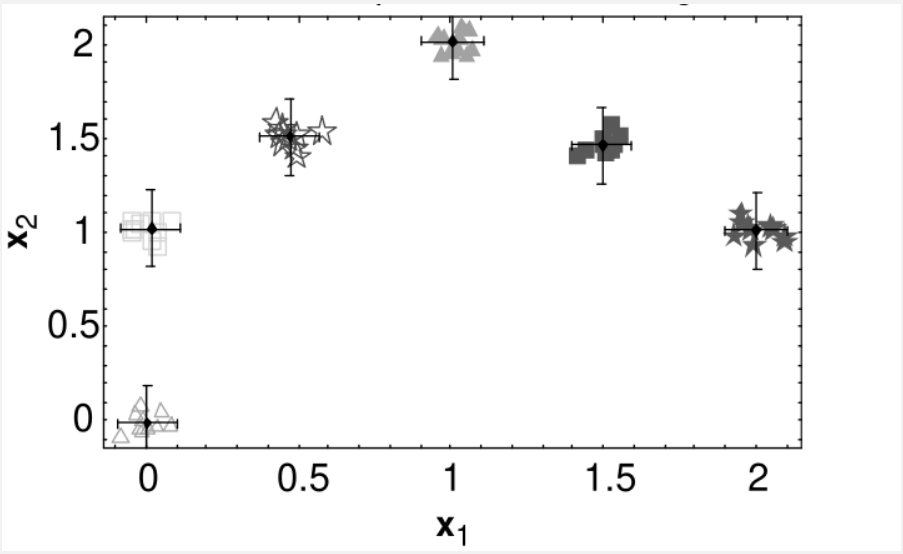

شکل ۸: داده‌های خوشه‌بندی شده شبکه SOM پس از آموزش

از مزایا و معایب این دو الگوریتم می‌توان به موارد زیر اشاره کرد:

پاسخ

(آ) **K-Means**:

i. مزایا:

- الگوریتم K-Means نسبت به شبکه SOM از سرعت بالا تری برخوردار است. دلیل این افزایش سرعت، سادگی پیاده‌سازی آن به نسبت SOM است.
- بر روی داده‌های بزرگ به‌خوبی کار می کند

ii. معایب:

- کاملا وابسته و حساس به مقداردهی اولیه برای نقاط مربوط به K هاست.
- برای خوشه‌یابی داده‌هایی که ساختار غیر محدب دارند، نامناسب است.
- وابستگی شبکه به مشخص کردن تعداد خوشه‌ها پیش از اجرای الگوریتم

(ب) **SOM**:

i. مزایا:

- کاربردهای گسترده به جز خوشه‌یابی
- بدست آوردن روابط پیچیده میان داده‌ها

ii. معایب:

- بار محاسباتی بیشتر و سرعت کمتر نسبت به الگوریتم K-Means
- وابسته بودن شبکه به پارامترهای مختلف ورودی مثل نرخ یادگیری، سایز همسایگی و ...

*

References

[1] Data Mining: Practical Machine Learning Tools and Techniques, 2016.

[2] Neural Networks for Applied Sciences and Engineering, 2006 by Taylor & Francis Group, LLC

[3] Frey BJ, Dueck D. Clustering by passing messages between data points. science. 2007 Feb 16;315(5814):972-6.

[4] Sculley D. Web-scale k-means clustering. InProceedings of the 19th international conference on World wide web 2010 Apr 26 (pp. 1177-1178).

[5] MacQueen J. Some methods for classification and analysis of multivariate observations. InProceedings of the fifth Berkeley symposium on mathematical statistics and probability 1967 Jun 21 (Vol. 1, No. 14, pp. 281-297).

[6] Comaniciu D, Meer P. Mean shift: A robust approach toward feature space analysis. IEEE Transactions on pattern analysis and machine intelligence. 2002 May;24(5):603-19.

[7] Ng A, Jordan M, Weiss Y. On spectral clustering: Analysis and an algorithm. Advances in neural information processing systems. 2001;14.

۲. مجموعه داده ارائه شده در این پروژه شامل رویدادهای سه‌سال متوالی از ۲۰۲۲ تا ۲۰۲۴ است که از سایت ویکی‌پدیا جمع‌آوری شده است. داده‌ی مربوطه را بارگزاری کنید و پیش‌پردازش‌های متنی شامل حذف کلمات ایست (Stop word)، واحدسازی کلمات (Tokenization) و تبدیل به بردارهای GloVe را روی آ ن انجام دهید.

پاسخ

فایل کد در مسیر `Code/Q1-P3.ipynb` موجود است. ابتدا کتابخانه‌های مورد نیاز برای کار با متن را نصب می‌کنیم، کتابخانه‌هایی مانند:

(a) `nltk`

(b) `textblob`

(c) `minisom`

پس از نصب کتابخانه‌ها، دیتاست موجود (فایل `WikipediaEvents.csv`) را می‌خوانیم. ابعاد این دیتاست `473 ,1` است.

```
shape of dataset: (473, 1)
[4]:
```

	text
0	January 1, 2022 – The Regional Comprehensive E...
1	January 2, 2022 – Abdalla Hamdok resigns as Pr...
2	January 4, 2022 – The five permanent members o...
3	January 5, 2022 – A nationwide state of emerge...
4	January 6, 2022 – The CSTO deploys a "peacekee...

شکل ۹: دیتاست ورودی

در ادامه، عملیات Pre-processing شامل کوچک کوچک کردن تمامی حروف، حذف علائم نگارشی، اعداد و کاراکترهای newline را حذف می‌کنیم. این عملیات‌ها در تابع `clean_text` نوشته شده است. پس از اعمال تابع نام‌برده بر روی دیتاست موجود، همه متن به حروف کوچک تبدیل می‌شود، تاریخ تمامی سال‌ها حذف می‌شود و فقط ماه مورد نظر باقی می‌ماند، همچنین کاراکترهای اضافی مانند - و , نیز حذف شده است. دیتاست پس از انجام این مراحل به صورت زیر می‌شود:

```
[17]: 0       january    the regional comprehensive economic...
      1       january    abdalla hamdok resigns as prime min...
      2       january    the five permanent members of the u...
      3       january    a nationwide state of emergency is ...
      4       january    the csto deploys a peacekeeping mis...
                                    ...
      468           october    georgian presidential election
      469          november     namibian general election
      470          november    romanian presidential election
      471  november   lee hsien loong prime minister of s...
      472          december    croatian presidential election
      Name: text, Length: 473, dtype: object
```

شکل ۱۰: دیتاست ورودی پس از حذف علائم نگارشی و کوچک سازی کلمات

پاسخ

برای پیدا کردن کلمات ایست، در دیتاست، از ماژول stopwords استفاده می‌کنیم. کلمات پرتکرار پیدا شده در این دیتاست به‌صورت زیر است:

```
['i', 'me', 'my', 'myself', 'we', 'our', 'ours', 'ourselves', 'you', "you're", "you've", "you'll", "you'd", 'your', 'yours', 'yourself', 'you
rselves', 'he', 'him', 'his', 'himself', 'she', "she's", 'her', 'hers', 'herself', 'it', "it's", 'its', 'itself', 'they', 'them', 'their', 't
heirs', 'themselves', 'what', 'which', 'who', 'whom', 'this', 'that', "that'll", 'these', 'those', 'am', 'is', 'are', 'was', 'were', 'be', 'b
een', 'being', 'have', 'has', 'had', 'having', 'do', 'does', 'did', 'doing', 'a', 'an', 'the', 'and', 'but', 'if', 'or', 'because', 'as', 'un
til', 'while', 'of', 'at', 'by', 'for', 'with', 'about', 'against', 'between', 'into', 'through', 'during', 'before', 'after', 'above', 'belo
w', 'to', 'from', 'up', 'down', 'in', 'out', 'on', 'off', 'over', 'under', 'again', 'further', 'then', 'once', 'here', 'there', 'when', 'wher
e', 'why', 'how', 'all', 'any', 'both', 'each', 'few', 'more', 'most', 'other', 'some', 'such', 'no', 'nor', 'not', 'only', 'own', 'same', 's
o', 'than', 'too', 'very', 's', 't', 'can', 'will', 'just', 'don', "don't", 'should', "should've", 'now', 'd', 'll', 'm', 'o', 're', 've', 'y
', 'ain', 'aren', "aren't", 'couldn', "couldn't", 'didn', "didn't", 'doesn', "doesn't", 'hadn', "hadn't", 'hasn', "hasn't", 'haven', "haven't
", 'isn', "isn't", 'ma', 'mightn', "mightn't", 'mustn', "mustn't", 'needn', "needn't", 'shan', "shan't", 'shouldn', "shouldn't", 'wasn', "was
n't", 'weren', "weren't", 'won', "won't", 'wouldn', "wouldn't"]
```

شکل ۱۱: کلمات ایست

همچنین پس از پیدا کردن کلمات، برای حذف آنها تابع remove_stopwords را نوشته‌ایم. پس از حذف، خروجی به صورت زیر می‌شود:

```
[31]: 0      january regional comprehensive economic partne...
      1      january abdalla hamdok resigns prime minister ...
      2      january five permanent members un security cou...
      3      january nationwide state emergency declared ka...
      4      january csto deploys peacekeeping mission kaza...
                                 ...
      468              october georgian presidential election
      469                  november namibian general election
      470              november romanian presidential election
      471    november lee hsien loong prime minister singap...
      472              december croatian presidential election
      Name: text, Length: 473, dtype: object
```

شکل ۱۲: خروجی پس از حذف کلمات ایست

پس از این مرحله، نوبت به Tokenization می‌رسد. برای انجام آن از ماژول punkt استفاده می‌کنیم. پس از انجام Tokenization خروجی به‌صورت زیر می‌شود:

```
[36]: 0      [january, regional, comprehensive, economic, p...
      1      [january, abdalla, hamdok, resigns, prime, min...
      2      [january, five, permanent, members, un, securi...
      3      [january, nationwide, state, emergency, declar...
      4      [january, csto, deploys, peacekeeping, mission...
                                 ...
      468          [october, georgian, presidential, election]
      469              [november, namibian, general, election]
      470          [november, romanian, presidential, election]
      471    [november, lee, hsien, loong, prime, minister,...
      472          [december, croatian, presidential, election]
      Name: text, Length: 473, dtype: object
```

شکل ۱۳: خروجی عملیات Tokenization

پس از Tokenization می‌بایست تبدیل کلمات به بردار را انجام دهیم. برای انجام این کار، از مدل ازپیش آموزش داده شده GloVe استفاده می‌کنیم. این مدل را می‌توان از اینجا دانلود کنید. پس از fine-tune کردن مدل، از تابع نوشته شده convert_to_vector برای تبدیل کلمات به بردار استفاده می‌کنیم.

پاسخ

خروجی‌های Vectorizrd شده را در فایلی با نام word2vec_out.csv ذخیره می‌کنیم و خروجی آن به صورت زیر می‌شود:

```
[53]:  0      [[0.39596, -0.73958, -0.33831, -0.10208, 0.354...
       1      [[0.39596, -0.73958, -0.33831, -0.10208, 0.354...
       2      [[0.39596, -0.73958, -0.33831, -0.10208, 0.354...
       3      [[0.39596, -0.73958, -0.33831, -0.10208, 0.354...
       4      [[0.39596, -0.73958, -0.33831, -0.10208, 0.354...
                                          ...
       468    [[0.41278, -0.76503, -0.28583, -0.04694, 0.315...
       469    [[0.27465, -0.67486, -0.21946, -0.13671, 0.456...
       470    [[0.27465, -0.67486, -0.21946, -0.13671, 0.456...
       471    [[0.27465, -0.67486, -0.21946, -0.13671, 0.456...
       472    [[0.48232, -0.76519, -0.30619, -0.027161, 0.25...
       Name: vectors, Length: 473, dtype: object
```

شکل ۱۴: کلمات تبدیل شده به بردار

در مرحله بعد، کلماتی که به بردار تبدیل کرده‌ایم را رسم می‌کنیم. ابعاد بردارهای بدست آمده (۷۴۶۵،۱۰۰) است. می‌بایست بعد آن را کاهش دهیم تا بتوانیم آن را نمایش دهیم. برای کاهش بعد از ماژول TSNE استفاده کرده‌ایم. ابعاد بردار را به (۷۴۶۵،۲) کاهش می‌دهیم و آن را رسم می‌کنیم. خروجی آن به‌صورت زیر می‌شود:

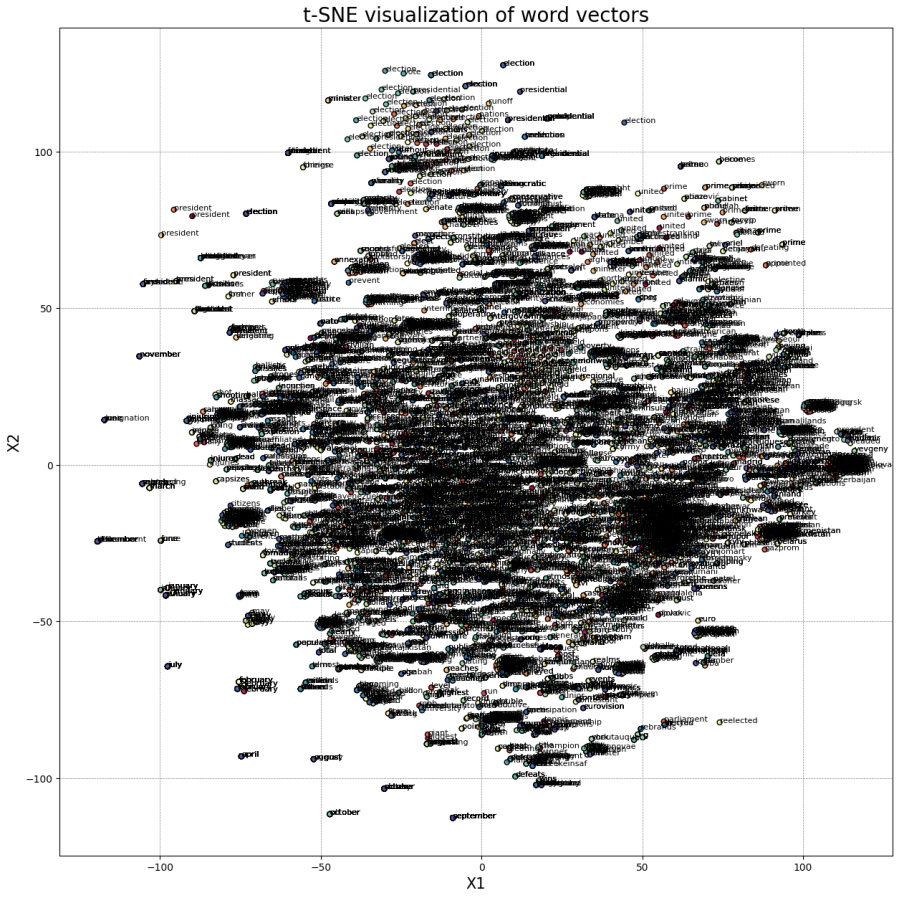

شکل ۱۵: نمایش بردارهای کلمات

پاسخ

به دلیل آنکه تعداد کلمات زیاد است و اسامی آن‌ها بر روی آن نوشته شده است و تصویر را شلوغ کرده است، لیبل‌ها را بر روی آن بر می‌داریم و دوباره آن را رسم می‌کنیم:

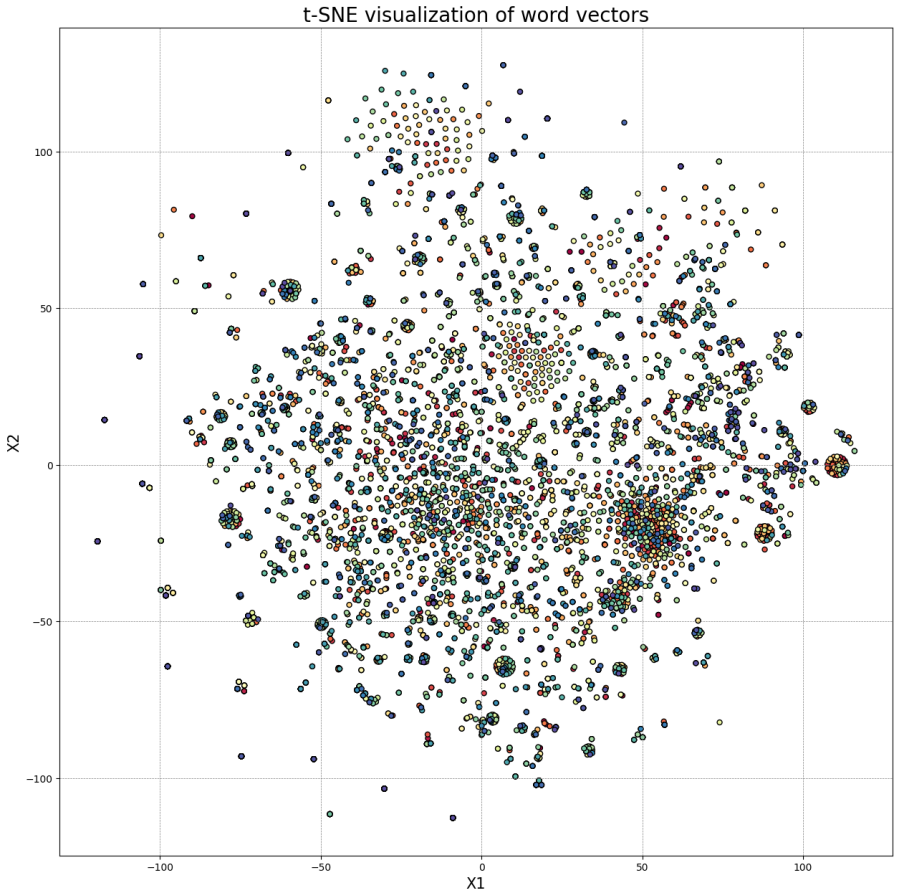

شکل ۱۶: نمایش برداری کلمات بدون اسامی

۳. پارامترهای ورودی مدل `minisom` را توضیح دهید. پیپارامترای شبکه خودسازمان‌ده خود را تنظیم کنید و شبکه را بر روی داده‌های مربوطه آموزش دهید. (مقادیر تمامی پارامترها را در گزارش خود اضافه کنید.) سپس به‌ازای هر داده‌ی ورودی واحد، منطبق (Best matching unit) با آن را به‌دست آورید و به‌عنوان نمایه‌ی داده‌ی مربوطه ذخیره کنید.

پاسخ

برای آموزش شبکه از کلاس `MiniSom` استفاده می‌کنیم. ورودی‌های این کلاس و مقادیر اولیه آن‌ها به صورت زیر هستند:

```
__init__(self, x, y, input_len, sigma=1.0, learning_rate=0.5,
decay_function=asymptotic_decay, neighborhood_function='gaussian'
topology='rectangular', activation_distance='euclidean',
random_seed=None)
```

در ادامه به توضیح هر پارامتر می‌پردازیم.

پاسخ

(آ) `x, y = (2, 3)`

`x, y` ابعاد نورون‌های خروجی را مشخص می‌کند. مثلا اگر مقدار آن را به‌ترتیب ۱ و ۵ قرار دهیم بدین‌معناست که نرون‌های خروجی در ساختار پشت‌سرهم در یک ساختار ۱ بعدی قرار می‌گیرند و ۵ نورون در خروجی شبکه داریم. پس در نتیجه ۵ خوشه داریم.

در این مسئله چون از تعداد خوشه‌ها اطلاعی نداریم مقدار آن را (۲،۳) درنظر گرفتیم. یعنی ساختار نورون‌های خروجی ۲ بعدی است و ۶ نورون (کلاس) در خروجی شبکه داریم.

(ب) `input_len=vectors_2d.shape[1]`

پارامتر `input_len` طول (بعد) داده‌های ورودی شبکه‌را مشخص می‌کند و چون در مسئله ما داده‌ها ۲ بعدی هستند، پس این پارامتر را برابر با `vectors_2d.shape[1]` یعنی مقدار ۲ قرار می‌دهیم.

(ج) `sigma=0.5`

پارامتر بعدی `sigma` است. این پارامتر، به نوعی نماینده انحراف معیار است و شعاع همسایگی را مشخص می‌کند. برای مثال در تکرار t مقدار $\sigma(t)$ به صورت زیر محاسبه می‌شود:

$$\sigma(t) = \frac{\sigma}{1 + \frac{t}{T}}, \qquad T = \frac{\text{number of iteration}}{2}$$

هر چقدر مقدار این پارامتر را کوچکتر بگیریم، دقت خوشه‌بندی بالاتر می‌رود و خطای آموزش کمتر می‌شود. مقدار پیش‌فرض این پارامتر، ۱ است که ما در این مسئله آن را ۰/۵ درنظر گرفتیم.

(د) `learning_rate=0.1`

پارامتر `learning_rate` نرخ یادگیری شبکه را مشخص می‌کند. این ضریب در اصلاح وزن نورون برنده شده خودش را نشان می‌دهد (در سوال اول به‌طور کامل توضیح داده شد). هر چقدر مقدار این پارامتر بزرگ باشد، شبکه ممکن است دچار ناپایداری شود. رنج نرمال این پارامتر در بازه ای بین ۰/۰۱ تا ۰/۱ قرار دارد. در این کلاس به طور پیش‌فرض مقدار نرخ‌یادگیری ۰/۵ فرض شده است اما ما در این مثال مقدار آن را ۰/۱ قرار دادیم.

(ه) `decay_function=asymptotic_decay`

این پارامتر، مقدار σ و `learning_rate` را در هر دوره کاهش می‌دهد. مقدار پیش فرض آن بر روی تابع `asymptotic_decay` تنظیم شده است. این تابع به‌صورت زیر نوشته شده است:

```
def asymptotic_decay(learning_rate, t, max_iter):
return learning_rate / (1+t/(max_iter/2))
```

ورودی‌های آن `learning_rate` و ماکزیمم تکرار (`max_iter`) است.

(و) `neighborhood_function="gaussian"`

این پارامتر، تابع همسایگی نام دارد، وظیفه آن نگاشت وزن ها تحت این توابع است. به صورت پیش‌فرض بر روی تابع `gaussian` تنظیم شده است اما می‌توان توابع `mexican_hat`، `bubble` و `triangle` را نیز انتخاب کرد.

پاسخ

(آ) `topology="rectangular"`

این پارامتر نوع توپولوژی نقشه را مشخص می‌کند، دو گزینه دارد که می‌توان انتخاب کرد. `hexagonal` و `rectangular` که به‌صورت پیش‌فرض بر روی `rectangular` تنظیم شده است.

(ب) `activation_distance="euclidean"` این پارامتر تابع فاصله‌ای است که برای فعال شدن نقشه‌ها استفاده می‌شود مقدار پیش‌فرض آن بر روی `euclidean` تنظیم شده است اما می‌توان توابع `cosine`، `manhattan` و `chebyshev` را انتخاب کرد.

(ج) `random_seed=10`

این پارامتر رندوم بودن ورودی شبکه را تعیین می‌کند که به صورت پیش‌فرض بر روی `None` قرار دارد.

پس از معرفی پارامترهای ورودی شبکه، با استفاده از کلاس `minisom` شبکه را در ۵۰۰۰۰ دوره آموزش می‌دهیم و خوشه‌های مناسب را پیدا می‌کنیم. این عملیات را برای ۵۰ داده رندوم از میان مجموعه داده‌ها مجددا تکرار می‌کنیم و نتایج آن را گزارش می‌دهیم.
به ازای آموزش شبکه با همه داده‌ها در ۵۰۰۰۰ دوره آموزشی و با ۶ نرون دو بعدی در خروجی مقدار خطای شبکه به صورت زیر بدست آمده است:

```
[ 50000 / 50000 ] 100% - 0:00:00 left
quantization error: 30.247671225311823
```

شکل ۱۷: خطای شبکه

خروجی شبکه پس از آموزش به‌صورت زیر به‌دست می‌آید:

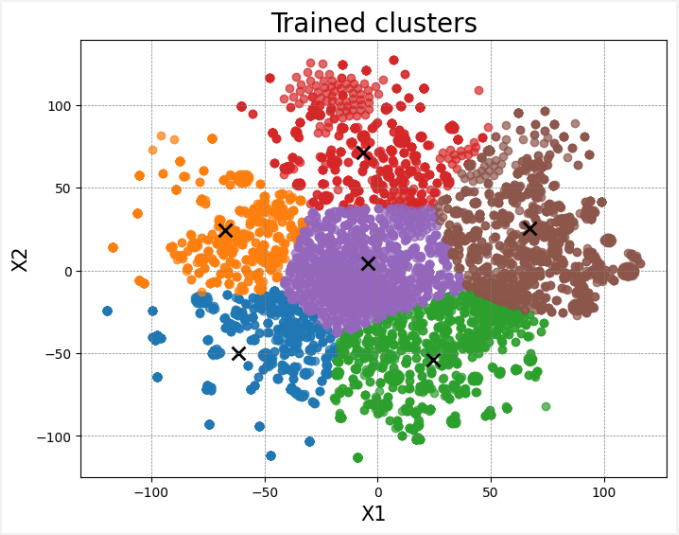

شکل ۱۸: داده‌های خوشه‌بندی شده پس از آموزش

۴. برای ۵۰ رویداد که به‌صورت تصادفی از مجموعه داده انتخاب شده‌اند، نقشه خروجی را رسم کنید. نقشه‌ی به‌دست آمده را تفسیر کنید.

پاسخ

ابتدا ۵۰ رویداد تصادفی را انتخاب و آن را رسم می‌کنیم:

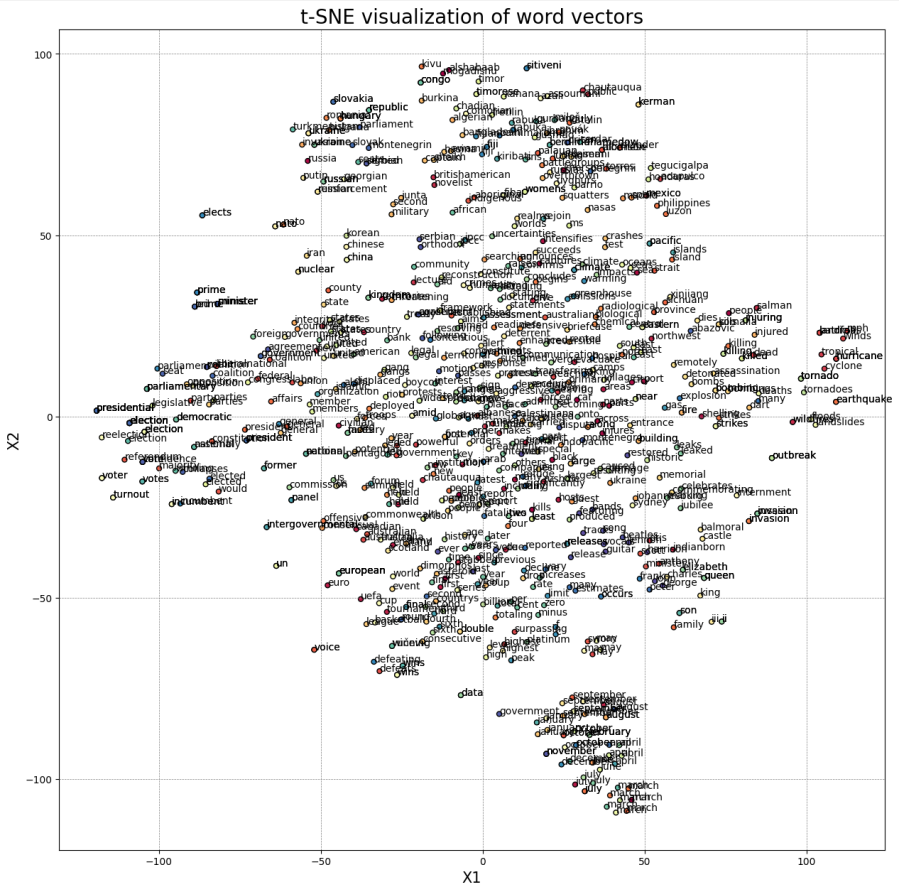

شکل ۱۹: داده‌های رندوم انتخاب شده

سپس شبکه را با داده‌های جدید (رندم) با همان پارامترهای قبل آموزش می‌دهیم. خروجی شبکه به صورت زیر می‌شود:

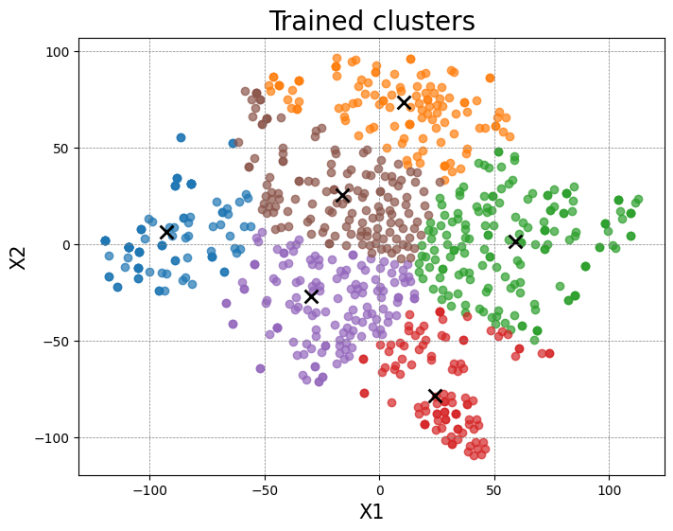

شکل ۲۰: داده‌های رندوم خوشه‌بندی شده

پاسخ

خطای آموزش نیز برای داده‌های رندوم به‌صورت زیر به‌دست می‌آید:

```
[ 50000 / 50000 ] 100% - 0:00:00 left
quantization error: 27.780855002267383
```

شکل ۲۱: خطای آموزش

۵. فرآیند جست‌وجو را به‌صورت زیر برای سه رویداد دلخواه از سه‌سال گذشته انجام دهید. (می‌توانید از پرسش‌های موجود درفایل sample_questions.txt کمک بگیرید.) و خروجی مربوطه را در گزارش خود اضافه کنید.

- تبدیل پرسش به بردار
- پیداکردن نمایه‌ی متناسب با پرسش مربوطه
- پیدا کردن تمامی داده‌های خارجی نمایه‌ی مورد نظر
- محاسبه معیار شباهت کسینوسی و خروجی دادن بردارهای داده‌های خارجی با شباهت بیشتر از آستانه. (چرا معیار کسینوسی در این مسئله انتخاب مناسبی است؟)

پاسخ

در این قسمت ۱۴ سوال به‌صورت نمونه به ما داده شده است:

```
Who won the 2022 soccer world cup?
When did Sweden join NATO?
Who joined NATO in 2023?
Who joined NATO in 2024?
Which is the 31st member of NATO?
Which is the 32nd member of NATO?
Who won the Cricket World Cup in 2023?
Who defeated India in Cricket World Cup final in 2023?
Name the former prime minister of Japan that was assassinated in
2022?
When did Chandrayaan-3 land near the south pole of the Moon?
Where did Chandrayaan-3 land on the Moon?
Who acquired Twitter in 2022?
Who owns Twitter?
Who acquired Activision Blizzard in 2023?
```

در این قسمت در ابدا مشابه با قبل پرسش‌های داده شده را به بردارهای GloVe تبدیل کرده و مجددا خوشه‌یابی را انجام می‌دهیم. بردارهای تبدیل شده را در فایلی با نام sample_questions_vector.csv ذخیره می‌کنیم.

خروجی این تبدیل به‌صورت زیر می‌شود

پاسخ

```
0     [[0.76222, 0.4244, 0.52142, -0.17333, 0.88267,...
1     [[0.30449, -0.19628, 0.20225, -0.61687, -0.684...
2     [[-0.12698, -0.093075, -0.9536, -0.55698, 0.51...
3     [[-0.12698, -0.093075, -0.9536, -0.55698, 0.51...
4     [[-0.54264, 0.41476, 1.0322, -0.40244, 0.46691...
5     [[-0.54264, 0.41476, 1.0322, -0.40244, 0.46691...
6     [[0.76222, 0.4244, 0.52142, -0.17333, 0.88267,...
7     [[-0.55123, -0.071932, 0.64235, -0.40988, 0.35...
8     [[-0.038194, -0.24487, 0.72812, -0.39961, 0.08...
9     [[0.30449, -0.19628, 0.20225, -0.61687, -0.684...
10    [[0.30449, -0.19628, 0.20225, -0.61687, -0.684...
11    [[0.91016, -0.32978, -0.1976, 0.26211, 0.52823...
12    [[0.50264, -0.066676, 0.066302, -0.0039705, 0....
13    [[0.91016, -0.32978, -0.1976, 0.26211, 0.52823...
Name: vectors, dtype: object
```

شکل ۲۲: تبدیل سوالات به بردار

نمایش ۲بعدی بردارها به‌صورت زیر می‌شود:

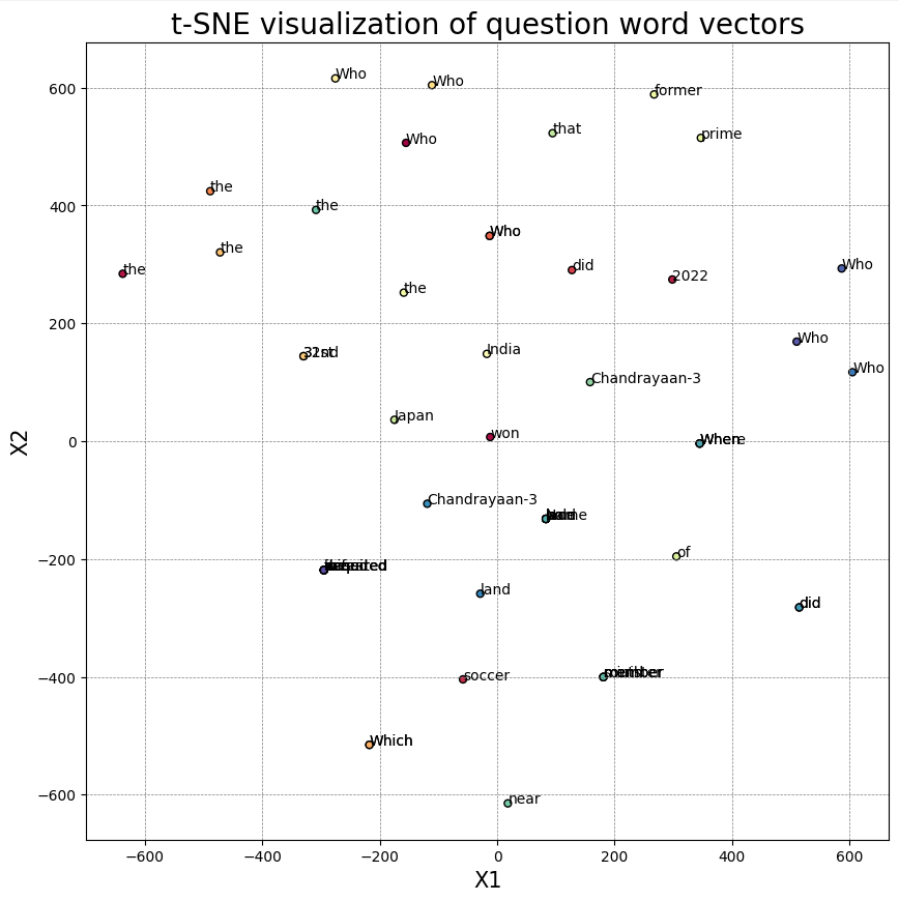

شکل ۲۳: نمایش ۲بعدی بردارهای سوال

پاسخ

خروجی خوشه‌بندی شده به‌صورت زیر می‌شود:

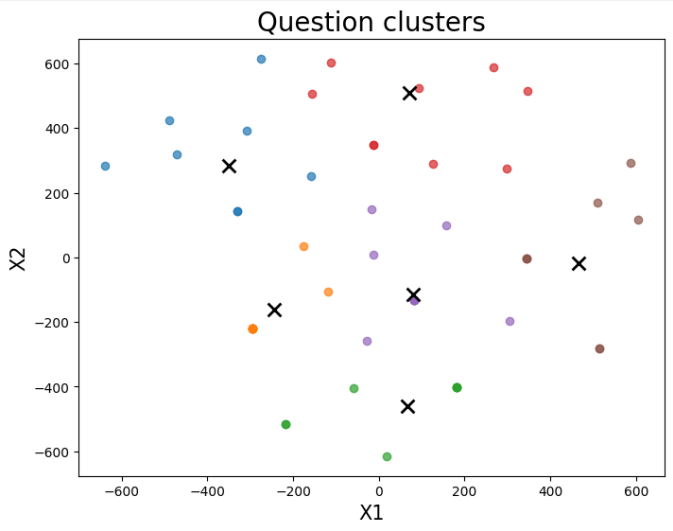

شکل ۲۴: سوالات خوشه‌بندی شده

سپس به سراغ معیار شباهت کسینوسی می‌رویم. معیار شباهت کینوسی، معیاریست برای بررسی شباهت میان دو بردار غیر صفر بر اساس کسینوس زاویه بین آنها که درنتیجه مقداری بین ۱- و ۱ بدست می‌آید. مقدار ۱- دوبردار متعامد و مقدار ۱ دو بردار مشابه را نشان می‌دهد.

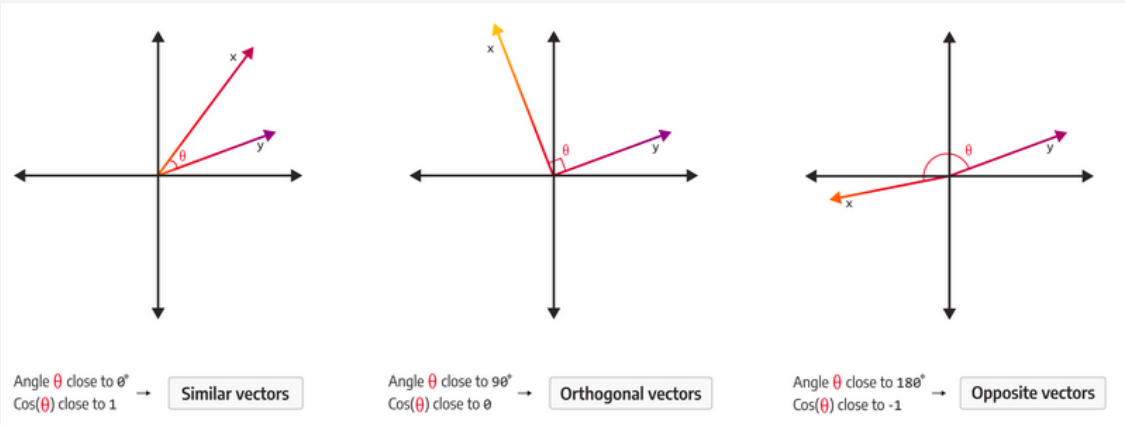

شکل ۲۵: معیار شباهت کسینوسی

شباهت کسینوسی بین دو بردار به صورت زیر تعریف می‌شود:

$$\text{similarity(A, B)} \quad = \quad cos(\theta) = \frac{A.B}{\|A\|\|B\|} = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2} \sum_{i=1}^{n} B_i^2}$$

برای بدست آوردن شباهت، از `cosine_similarity` کتابخانه `sklearn` استفاده کردیم. ابعاد بردار شباهت خروجی، (7465, 126) شده است که مقدار بیشترین شباهت 0.78742 و کمترین شباهت، 0.50964- شده است.

پاسخ

```
maximum cosine similarity is:  0.7874246238806482
minimum cosine similarity is:  -0.509642610657858
(7465, 126)
--------------------------------------------------
[[ 0.43380143  0.55897001  0.01306567 ...  0.          0.
   0.        ]
 [ 0.29249495  0.53389831  0.15125115 ...  0.          0.
   0.        ]
 [ 0.16831103  0.51552992  0.07107112 ...  0.          0.
   0.        ]
 ...
 [ 0.18637699  0.20286848 -0.1090457  ...  0.          0.
   0.        ]
 [ 0.42644385  0.50590687  0.1077436  ...  0.          0.
   0.        ]
 [ 0.43460016  0.53521315  0.10645972 ...  0.          0.
   0.        ]]
```

شکل ۲۶: خروجی شباهت